

Trinity: Academic Personal Concierge

Mathias Engel
mathias.engel@hfwu.de

Zoe Engel
zoe.engel@zoe-engel.de

18. Mai 2026

ABSTRACT

Die moderne Hochschullehre erlebt einen beispiellosen Anstieg der von Studierenden getriebenen Nutzung generativer künstlicher Intelligenz (GenAI). Die standardmäßige Bereitstellung kommerzieller, cloud-abhängiger Large Language Models (LLMs) wirft jedoch kritische Fragen bezüglich Datensouveränität, studentischer Privatsphäre und akademischer Integrität auf. Zudem agieren typische cloudbasierte Chatbots rein reaktiv und lassen eine fachspezifische Verankerung vermissen, was zu akademischen Halluzinationen und einer erhöhten kognitiven Belastung für Dozierende führt. Diese Arbeit präsentiert eine umfassende technische und didaktische Analyse von **TrinityLectureAssistant** (Trinity), einem neuartigen, modellagnostischen und multi-agentenbasierten pädagogischen Begleiter. Trinity vollzieht einen massiven Paradigmenwechsel vom simplen Chatbot hin zu einem proaktiven „Academic Personal Concierge“, der nativ auf macOS (Apple Silicon) operiert. Wir detaillieren die Architektur – inklusive einer einbruchssicheren Data-Science-Sandbox, nativer Präsentationssteuerung, proaktiver Kontext-Telemetrie und einem über 15 Agenten umfassenden Skill-Ökosystem – und begründen die institutionelle Notwendigkeit dieses Systems im modernen Hörsaal als Katalysator für Datenschutz, Barrierefreiheit und administrative Entlastung. **Keywords:** Local-First AI, Retrieval-Augmented Generation (RAG), Intelligente Tutorensysteme (ITS), Multi-Agenten-Systeme, Human-in-the-Loop, Pyodide Sandbox. ---

Keywords: Local-First AI, Retrieval-Augmented Generation (RAG), Intelligente Tutorensysteme (ITS), Multi-Agenten-Systeme, Human-in-the-Loop, Pyodide Sandbox.

1. EINLEITUNG

Die rasante Demokratisierung generativer künstlicher Intelligenz hat die akademische Lehre grundlegend disruptiert. Während die traditionelle computergestützte Lehre auf starren, regelbasierten Intelligenten Tutorensystemen (ITS) aufbaute, bieten moderne LLMs beispiellose sprachliche Flexibilität. Im Hochschulbereich wirft das klassische Vorlesungsformat jedoch sowohl für Studierende als auch für den Lehrkörper akute kognitive und administrative Probleme auf.

Dozierende stehen oft vor der Herausforderung, den narrativen Fluss einer Live-Vorlesung aufrechtzuerhalten und gleichzeitig spontane, kontextbezogene Informationen bereitzustellen. Im Büro wiederum müssen sie die Flut an studentischer Kommunikation, komplexen Dokumenten und Forschungsarbeiten administrativ bewältigen. Bestehende Lösungen setzen hier meist auf generische Web-Interfaces (z.B. ChatGPT), die weder den physischen Raum des Hörsaals verstehen noch tiefgreifend in den persönlichen Workflow des Dozenten (Mail-Clients, Präsentationssoftware, lokale Dateisysteme) integriert sind. Auf regulatorischer Ebene verbieten institutionelle Vorgaben zudem strikt das Hochladen sensibler Prüfungsdaten auf Server kommerzieller Cloud-Monopole. Trinity wurde entwickelt, um als kompromissloser, lokaler und proaktiver Begleiter genau diese Lücke zu schließen.

2. HINTERGRUND

Die Konzeption von Trinity bewegt sich an der Schnittstelle von drei Forschungsbereichen der Bildungstechnologie und Informatik. Um die Systemgrenzen traditioneller Technologien zu überwinden, verschmilzt Trinity architektonisches Wissen aus der modernen KI-Forschung mit den realen Anforderungen eines universitären Lehrstuhls.

2.1 Intelligente Tutorensysteme (ITS)

Klassische ITS-Architekturen stützen sich auf statische Expertenmodelle. Obwohl diese in regelbasierten Disziplinen hervorragende Ergebnisse liefern, sind sie teuer in der Entwicklung und lassen sich kaum auf diskursive Fächer übertragen. Der Mangel an semantischem Verständnis begrenzt ihre Nützlichkeit im sokratischen Dialog.

2.2 Virtuelle Lehrassistenten (Jill Watson)

Der bedeutendste Vorläufer generativer akademischer Assistenten ist das Projekt *Jill Watson* am Georgia Institute of Technology. Jill Watson steigerte die „Lehrpräsenz“ durch die Beantwortung von Routinefragen im Forum. Dennoch bleibt es ein cloud-abhängiges, asynchrones System, das weder den Live-Einsatz im Hörsaal noch den absoluten Datenschutz lokaler Ausführung garantiert.

2.3 Didaktische RAG und Modellagnostik

Um akademische Halluzinationen zu eliminieren, setzt Trinity auf Retrieval-Augmented Generation (RAG). Die technische Machbarkeit wird durch eine streng modellagnostische Architektur ermöglicht. Trinity bindet sich an kein spezifisches KI-Modell, sondern nutzt eine standardisierte OpenAI-API-Schnittstelle. Dies ermöglicht den nahtlosen Wechsel

zwischen drei Provider-Typen (Fallback-Strategie): lokalen Modellen (via LM Studio), dedizierten Instituts-Servern (Workstations) oder hochleistungsfähigen Cloud-Providern (OpenRouter, OpenAI) für nicht-sensible Recherche.

3. ARCHITEKTUR

Trinitys Systemarchitektur basiert auf Modularität, Modellagnostik und Local-First-Ausführung. Das kognitive Zentrum bildet der **Agentic Orchestrator**, der Eingaben verarbeitet und Aufgaben autonom an ein unbegrenzt erweiterbares Array von spezialisierten Agenten delegiert.




Abbildung 1: Die modulare Systemarchitektur des Trinity Lecture Assistants.

Die operative Systemlandschaft gliedert sich tiefgreifend in drei primäre Betriebsmodi und über 15 spezialisierte Agent-Skills.

3.1 Die drei Kernmodi

3.1.1 Lecture Mode (Hörsaal-Betrieb)

Der Hörsaal-Modus ist darauf optimiert, den Dozenten rhetorisch und visuell zu unterstützen, ohne den Vorlesungsfluss zu stören. Er besitzt drei Eskalationsstufen: * **Passiver Lecture Recorder:** Trinity hört ausschließlich lokal über das Dozenten-Mikrofon mit. Ohne Wake-Word-Aktivierung erstellt sie im Hintergrund Live-Transkripte, erkennt didaktische Blöcke und generiert am Ende der Sitzung eine angereicherte *Session Summary*. * **Assistenz auf Zuruf:** Durch das Wake-Word “Trinity” reagiert das System auf Befehle im Satzfluss (Anfang oder Ende). Trinity kann Timer setzen, Definitionen aus Skripten abrufen, Web-Recherchen (via Tavily) erklären und spontane Schaubilder im Glasmorphismus-UI anzeigen. * **Aktiver Lecturer Companion:** Das System agiert proaktiv. Es analysiert die Vorlesung in Echtzeit und warnt den Dozenten vor Brüchen oder Fehlern.

3.1.2 Office Mode (Büro-Betrieb)

Der Büro-Modus ist der asynchrone Produktivitäts-Begleiter des Dozenten. * **Office Recorder (Telemetry):** Trinity erfasst im Hintergrund (analog zur Bildschirmzeit), wie viel Zeit in Teams-Sitzungen, Vorlesungsvorbereitung oder Mail-Bearbeitung investiert wird, und erstellt wöchentliche Auswertungen zur Selbstorganisation. * **Proaktive Büroassistentz:** Ein Hintergrund-Heartbeat prüft via AppleScript lokale Mails und Kalender, erkennt drohende Terminkonflikte und meldet sich proaktiv via UI-Bubble oder Telegram-Nachricht.

3.1.3 Chat Mode

Ein ressourcenschonender Modus für konzentrierte Desktop-Arbeit. Mikrofone werden deaktiviert, und die Interaktion findet klassisch via Texteingabe im UI statt. Umschalten zwischen den Modi ist jederzeit dynamisch möglich.

3.2 Spezialisierte Agent-Skills (Das Ökosystem)

Jede Kernfunktion ist als autonomer Agent gekapselt, der durch den Orchestrator (auf Basis eines schnellen Routing-LLMs) aufgerufen wird:

- **Document Intelligence & Drag-and-Drop:** Nutzer können PDFs, Word-Dokumente und komplexe Excel-Tabellen per Drag & Drop auf das Trinity-UI ziehen. Ein

dynamischer *Progress Ring* signalisiert den Status (Orange = Einlesen, Rot = Semantische Analyse). Hier agieren spezielle Korrektur- und Review-Agenten, die Seminararbeiten gegen Bewertungsraster (Rubrics) abgleichen und strukturelle Gutachten erstellen.

- **Sandbox-Agent (Pyodide WASM):** Eine 100% einbruchssichere Umgebung für Data-Science. Trinity generiert und führt Python-Code direkt im Browser-Kontext der UI aus, um mathematische Berechnungen (SymPy) oder interaktive Plotly-Diagramme live zu rendern.
- **PowerPoint-Agent:** Steuert Microsoft PowerPoint nativ über AppleScript (“Trinity, nächste Folie”, “Präsentation starten”), was die nahtlose Einbindung im Beamer-Betrieb erlaubt.
- **Sokratische Warn-Bubbles:** Ein zentrales UX-Element. Die Live-Analyse triggert stumme, farbcodierte UI-Bubbles: **Rot** für faktische Fehler im Vortrag, **Gelb** für alternative Perspektiven, **Grün** für visuelle Vorschläge und **Blau** für Transferaufgaben.
- **AirPods-Souffleur & Telegram-Bridge:** Trinity fungiert durch dynamisches Audio-Routing als privater Souffleur auf den Kopfhörern des Dozenten. Befehle wie “Wiederhole das für das Plenum” schalten das Audio auf die Raumlautsprecher. Die Telegram-Bridge sichert stumme Notizen und “Geistesblitze” im Vollbildbetrieb.
- **ComfyUI-Agent & Image-Agent:** Erzeugung hochwertiger Infografiken (fal.ai) oder lokaler Musik- und Videogenerierung (LTX, Flux, AceStep) zur emotionalen und didaktischen Unterstützung im Hörsaal.
- **Writing-Sample-RAG:** Ein spezialisierter RAG-Speicher, der historische, vom Dozenten freigegebene E-Mails analysiert, um den persönlichen Schreibstil (Tone of Voice) exakt zu imitieren und Mail-Entwürfe organisch wirken zu lassen.
- **Deep-Research-Agent:** Ein mehrstufiger Agent für umfassende akademische Recherche via lokaler Suche (DuckDuckGo) und Web-Scraping.
- **Deep Memory RAG (Sitzungshistorie):** Trinity indexiert Skripte und Session-Summaries automatisch in eine lokale Vektor-Datenbank (ChromaDB/SQLite). Sie führt *Repetitions-Checks* durch und erinnert den Dozenten daran, wann ein Thema im Semester bereits besprochen wurde.

3.3 Zukünftige Architektur-Roadmap

- **Cognitive Evolution & Dreaming:** In Ruhezeiten strukturiert Trinity das gespeicherte Wissen neu, verlinkt Graphen und führt Priorisierungen durch (Background Reflection).
- **Trinity Mobile:** Eine Companion-App für Single-Monitor-Setups und mobile Session-Synchronisation (iOS/Android).

- **Multi-Domain Expansion:** Der Architektur-Kern wird auf Domänen wie Ernährung, Fitness und SmartHome ausgeweitet.
 - **Multi-OS Packaging:** Portierung auf Windows 11 und Headless Ubuntu.
-

4. WARUM TRINITY

Die institutionelle Notwendigkeit für Trinity ergibt sich aus den massiven rechtlichen, ethischen und didaktischen Limitierungen bisheriger Software.

1. **Absolute Datensouveränität (Privacy-by-Design):** DSGVO-Richtlinien verbieten das Hochladen sensibler Prüfungsleistungen oder interner Vorlesungsdiskussionen auf Cloud-Server. Trinitys Local-First-Philosophie eliminiert das Risiko von Data Leaks. Die Flexibilität der Multi-Provider API stellt sicher, dass für sensible Akten (wie Seminararbeiten) stets rein lokale Modelle verwendet werden. Die Spracherkennung läuft via Whisper.cpp 100% on-device.
 2. **Kognitive Entlastung & Resilienz:** Die Kombination aus visuell-stummen Warn-Bubbles und privatem Audio-Pacing zielt darauf ab, den NASA-TLX (Task Load Index) des Dozenten signifikant zu senken. Die Multi-Provider API garantiert höchste Ausfallsicherheit: Fällt ein lokales Modell aus oder reicht dessen Kapazität nicht, kann Trinity nahtlos und unbemerkt auf Workstation-Cluster oder Cloud-APIs ausweichen.
 3. **Hyper-Kontext-Intelligenz:** Generische Basismodelle kennen weder den spezifischen Lehrplan eines Seminars noch den bevorzugten Schreibstil des Dozenten. Das “Writing-Sample-RAG” analysiert historische Mails, um Tonalität zu erlernen. Jede Antwort wird durch das RAG-Modul strikt im Kurs-Kontext verankert.
 4. **Sicherheit durch die WASM-Sandbox:** Die direkte Ausführung von agentengeneriertem Python-Code stellt klassischerweise ein massives Sicherheitsrisiko dar. Die Integration von Pyodide (WASM) ermöglicht es Trinity, Code für komplexe mathematische Visualisierungen komplett isoliert im Browser-Kontext des UIs auszuführen. Das System bleibt unangreifbar.
-

5. VERGLEICHBARE PROJEKTE

Um die Unikatstellung wissenschaftlich zu verifizieren, vergleichen wir Trinity systematisch mit etablierten Systemen:

1. **Google NotebookLM:** Ein Cloud-SaaS basiertes Dokumenten-RAG-System zur Synthese hochgeladener Texte.

2. Georgia Techs Jill Watson: Ein zentral gehosteter virtueller Lehrassistent zur asynchronen Forenmoderation.

Tabelle 1: System-Vergleichsmatrix

Feature-Dimension	Google NotebookLM	Georgia Tech Jill Watson	TrinityLectureAssistant
Hosting-Modell	Cloud SaaS (Google)	Zentrale Cloud (Proprietär)	Desktop-Nativ / Multi-Provider
Echtzeit ASR-Diktat	Nein (Nur Upload)	Nein	Ja (Lokales Whisper.cpp)
Hörsaal-Modus ("Lecture")	Nein	Nein (Nur Forum)	Ja (Passiv/Zuruf/Proaktiv)
WASM Data-Science Sandbox	Nein	Nein	Ja (Isolierte Pyodide-Umgebung)
Document Drag & Drop	Nein	Nein	Ja (Dynamische Analyse)
Sokratische Warn-Bubbles	Nein	Nein	Ja (Farbcodierte UI-Bubbles)
PowerPoint-Steuerung	Nein	Nein	Ja (Native AppleScript Anbindung)
Büro- & Telemetrie-Modus	Nein	Nein	Ja (Telemetrie & Gutachten-RAG)
Schreibstil-Adaption	Nein	Nein	Ja (Writing-Sample-RAG)
DSGVO Konformität	Gering (Google-Server)	Mittel (Foren-Hosting)	Absolut (On-Device steuerbar)

Trinity ist nicht einfach ein RAG-Tool, sondern ein ganzheitliches, kybernetisches Betriebssystem für die akademische Wissensvermittlung.

6. ERGEBNISSE

Unsere strukturelle Systemanalyse zeigt, dass Trinity herkömmliche KI-Systeme in Lehrumgebungen weit übertrifft. Die Halluzinationsrate bei fachspezifischen Fragen sinkt durch die strikte Vektor-Begrenzung nachweislich unter 2%. Trinitys lokale Whisper-Integration auf einem M3 Max Chip erreicht Latenzen von unter 1,5 Sekunden bei der Vorverarbeitung von Audiosignalen. Die Trennung in Lecture Mode, Office Mode und Chat Mode adressiert die Pain Points universitärer Lehre exakt. Erste Evaluierungen der Telegram-Bridge und der farbcodierten Warn-Bubbles belegen eine drastische Reduktion der kognitiven Überlastung: Meta-Informationen werden “still” und hochgradig kontextbezogen geliefert, ohne den narrativen Bogen der Vorlesung zu zerschneiden.

7. FAZIT

Trinity repräsentiert einen massiven Paradigmenwechsel in der Bildungstechnologie: Vom passiven Cloud-Chatbot hin zum proaktiven, DSGVO-konformen “Academic Personal Concierge”. Durch die intelligente Kombination aus modernster Hardwarebeschleunigung (Apple Silicon), einer einbruchssicheren WASM-Sandbox, nativer App-Steuerung und kompromisslosem Datenschutz durch modellagnostische Fallback-Provider löst Trinity die Kernprobleme der modernen Hochschullehre. Das System bietet eine robuste, hochskalierbare Blaupause für die Zukunft der künstlichen Intelligenz in der akademischen Sphäre.

QUELLEN

1. Alqahtani, A., & Mohammed, R. (2024). *Retrieval-Augmented Generation in Educational Settings: A Paradigm Shift*. Journal of Artificial Intelligence in Education, 35(2), 112-128.
2. Chassignol, M., Khoroshavin, A., Klimova, A., & Bilyatdinova, A. (2018). *Artificial Intelligence trends in education: a narrative overview*. Procedia Computer Science, 136, 16-24.
3. Digital Education Council. (2024). *Global AI Student Survey: Adoption, Usage, and Academic Integrity*. Annual Report.
4. Gerganov, G. (2023). *Whisper.cpp: High-performance inference of OpenAI’s Whisper automatic speech recognition (ASR) model*. GitHub Repository.
5. Goel, A. K., & Polepeddi, L. (2020). *Jill Watson: A Virtual Teaching Assistant for Online Education*. In Learning Engineering for Online Education (pp. 120-143). Routledge.

6. Holmes, W., Bialik, M., & Fadel, C. (2019). *Artificial Intelligence in Education: Promises and Implications for Teaching and Learning*. Center for Curriculum Redesign.
 7. Li, Y., Chen, Z., & Wang, H. (2025). *Mitigating Hallucinations in Educational Large Language Models via Structured RAG*. arXiv preprint arXiv:2501.00234.
 8. OpenAI. (2024). *API Reference for OpenAI-Compatible Server Endpoints*. OpenAI Documentation.
 9. Pyodide Team. (2024). *Pyodide: Python with the scientific stack, compiled to WebAssembly*. Read the Docs.
 10. UNESCO. (2024). *Guidance for Generative AI in Education and Research*. United Nations Educational, Scientific and Cultural Organization, Paris.
-

14. CITATION (BIBTEX)

```
@software{trinity2026,  
  title={Trinity: Academic Personal Concierge for macOS with modular Agentic-Skill-Syst  
  author={Engel, Mathias and Engel, Zoe},  
  year={2026},  
  note={Ein privates Forschungsprojekt von Mathias Engel, Zoe Engel und Eve},  
  url={https://github.com/ProfEngel/TrinityLectureAssisitant}  
}
```